

2 발표 대본 (쉽게 설명하는 버전, 약 12~15분 분량)

💡 사용법: 각 슬라이드마다 ① 핵심 한 줄 ② 풀어 말하기 ③ 다음 슬라이드 연결 멘트 순서로 구성했습니다. 그대로 읽지 말고 자기 말투로 바꿔 연습하세요.

🗣️ Slide 1 — 표지 (30초)

안녕하세요. 오늘 발표할 주제는 **노인 음성 인식 성능 개선을 위한 Whisper PEFT 파인튜닝**입니다.

한 줄로 요약하면, **AI 음성 인식 모델인 Whisper가 노인 어르신 목소리를 잘 못 알아듣는 문제를, 효율적인 파인튜닝 기법으로 해결할 수 있는지 검증하는 연구 계획**입니다.

오늘은 결과 발표가 아니라, 가설을 세우고 어떻게 실험할지를 설계하는 단계입니다. 함께 보시죠.

🗣️ Slide 2 — 목차 (20초)

발표는 4개 파트로 나뉩니다. Part 1에서 왜 이 연구가 필요한지를 설명하고, Part 2에서 이 연구의 핵심인 두 가지 가설을 제시합니다. 여기가 가장 중요합니다. Part 3에서는 어떤 데이터와 기술로 검증할지 방법론을 다루고, Part 4에서는 어떻게 측정하고 통계로 검증할지 실험 설계를 보여드립니다.

🗣️ Slide 3 — 용어 정의 (1분, 가장 친절하게)

본격적인 설명에 앞서, 자주 등장할 용어 6가지를 일상 비유로 정리했습니다.

STT는 사람 말소리를 글자로 받아 적는 AI입니다. 회의 녹음을 자동으로 회의록으로 만들어주는 그 기능이죠.

CER은 Character Error Rate, 즉 틀린 글자 비율입니다. 받아쓰기 시험에서 100자 중 10자 틀리면 CER 10%인 거죠. 낮을수록 좋습니다.

Whisper는 OpenAI가 만든 STT 모델인데, 무려 68만 시간의 음성으로 학습했습니다. 거의 대부분의 음성을 잘 알아듣는 만능 모델이에요.

PEFT는 Parameter-Efficient Fine-Tuning. 두꺼운 사전을 통째로 다시 쓰는 게 아니라, 부록만 새로 끼워넣어 업데이트하는 방식입니다.

LoRA는 PEFT의 한 종류예요. 책의 본문은 그대로 두고 포스트잇만 붙여 보충하는 느낌입니다.

VAD는 녹음에서 사람이 말한 부분만 골라내는 기능입니다.

이 6가지만 기억하시면 발표 따라오시는 데 무리 없으실 겁니다.

Slide 4 — 연구 배경 (45초)

우리나라 65세 이상 인구가 **20.3%**입니다. 다섯 명 중 한 명이 어르신이라는 얘기에요. 곧 초고령사회 진입을 앞두고 있습니다.

그런데 안타깝게도 작년 한 해 고독사로 돌아가신 분이 3,924명입니다. 매일 10명 넘게 혼자 돌아가신다는 거예요.

그래서 AI 돌봄, AI 말벗 같은 기술 수요가 폭발적으로 늘고 있는데, 핵심 문제는 기존 STT가 젊은 성인 목소리로만 학습됐다는 점입니다. 어르신 목소리는 잘 못 알아들어요. 이게 바로 우리가 풀어야 할 문제입니다.

Slide 5 — 문제 정의 (1분)

그럼 노인 음성이 구체적으로 뭐가 다를까요? 4가지 특성이 있습니다.

첫째, 발화 속도가 느립니다. 일반 성인의 60~70% 수준이에요. 이러면 모델이 "이 말이 끝났나?" 하고 헛갈려서 단어를 누락합니다.

둘째, 구음 장애가 있습니다. 틀니나 발음 불명료 때문에 발음이 뭉개지면 모델이 다른 글자로 바뀌어서 인식해요.

셋째, 문장 중간에 2초 이상 침묵이 들어갑니다. 이건 말이 끝난 게 아니라 숨 고르는 거 인데, AI는 이것을 "문장 끝"으로 오인해서 뒷부분을 통째로 날려버립니다.

넷째, 헛기침과 잡음이 섞여 들어갑니다.

이 4가지가 합쳐져서, 현재 Whisper의 노인 음성 CER은 20~30%로 추정됩니다. 일반인 대비 4~5배 나쁜 거예요. 받아쓰기 100자 중 25자가 틀리는 셈이죠.

Slide 6 — 연구 목적 (30초)

그래서 이 연구의 목적은 명확합니다. 노인 음성에 특화된 Whisper 파인튜닝 방법론을 정립하고, 그 효과를 정량적으로 검증하는 것입니다.

학술적으로는 두 가지 — 도메인 적응 전략 제안과 PEFT 효과의 정량 검증에 기여하고, 응용적으로는 노인 돌봄 AI 서비스의 핵심 기반 기술이 될 수 있습니다.

Slide 7 — 연구 가설 ★ (2분, 가장 강조)

이 슬라이드가 발표의 핵심입니다. 잠시 천천히 보겠습니다.

본 연구는 두 개의 가설을 검증합니다.

H1, 주가설입니다. "Whisper-large-v3 모델에 VOTE400 데이터셋으로 LoRA 기반 PEFT 파인튜닝을 적용하면, 노인 음성에서의 CER이 baseline 대비 통계적으로 유의하게 감소할 것이다." 즉, "노인 데이터로 어댑터만 살짝 학습시키면 진짜 좋아지는가?" 를 묻는 겁니다. 통계는 paired t-test로, 목표는 상대 개선율 30% 이상입니다.

H2, 부가설입니다. "VAD 임계값을 노인 음성 특성에 맞게 재조정하면, deletion error가 추가로 감소할 것이다." 아까 말씀드린 "문장 중간 2초 침묵을 자르지 않게" 만들면, 단

어 누락 오류가 줄어들는지 확인합니다.

하단에 칼 포퍼의 인용을 넣었는데요, "반증 가능하지 않은 이론은 과학이 아니다" 라는 뜻입니다. 본 연구의 가설은 데이터로 채택될 수도, 기각될 수도 있도록 엄밀하게 설계했다는 점을 강조하고 싶습니다.

 Slide 8 — 관련 연구 + Gap (1분)

본 연구의 학술적 위치를 짚고 가겠습니다.

기반 모델로 쓸 Whisper는 2023년 OpenAI 발표 모델, 효율적 학습 기법인 LoRA는 2021년 Microsoft 발표, 음성 표준 증강법인 SpecAugment는 2019년 Google 발표 논문입니다.

그런데 빈 공간이 있습니다. 노인 음성 STT 연구는 거의 다 영어권 데이터 기반이고, 한국어 노인 음성에 Whisper + PEFT를 결합한 연구는 사실상 부재합니다.

본 연구는 바로 이 공백, Research Gap을 채우는 첫 시도로 자리매김합니다.

 Slide 9 — 데이터셋 VOTE400 (1분)

그럼 어떤 데이터로 검증할까요? VOTE400입니다.

AI허브에서 받을 수 있고, ETRI와 마인즈랩이 공동 구축한 한국어 고령자 전용 음성 코퍼스예요. 400시간 이상, 화자 3,000명 이상, 65세 이상으로 구성됐습니다.

구성을 보면 **대화체 300시간(75%)**과 **낭독체 100시간(25%)**입니다.

분할 계획에서 한 가지 강조하고 싶은 게 있는데요, **화자 단위 분할(Speaker-disjoint

Split)**을 채택했습니다. 같은 사람이 train과 test에 동시에 들어가면 안 된다는 거예요. 이걸 안 지키면 모델이 "이 화자 본 적 있다"고 외워버려서, **데이터 누수(Data Leakage)**가 발생해 결과가 부풀려집니다. 학술적 엄밀성을 위한 필수 조치입니다.

또 화자 그룹을 정상 / 구음장애 / 80세 이상 초고령으로 계층화해서, 그룹별 성능 분석까지 가능하도록 설계했습니다.

 Slide 10 — 파이프라인 (45초)

전체 흐름은 이렇습니다. 왼쪽부터 보시면,

원음성 → 전처리(VAD·침묵·화자분리) → Whisper Encoder → LoRA Adapter → Whisper Decoder → 텍스트 6단계입니다.

색깔이 핵심입니다. 파란 박스는 학습하지 않고 그대로 두는 부분(Frozen), 주황 박스(LoRA)만 학습합니다.

전체 파라미터가 1,550M인데 학습은 0.5%인 8M만 합니다. 그래서 GPU 메모리도 절약되고, 데이터가 적어도 과적합이 잘 안 되는 거예요.

 Slide 11 — 전처리 (1분)

전처리를 노인 특성에 맞게 조정한 부분을 설명드리겠습니다.

VAD는 TensorFlow Lite 기반으로 가는데, 핵심은 임계값을 노인용으로 재튜닝하는 거예요. 기존 VAD는 0.5초 무음이면 발화 종료로 판단하는데, 노인은 2초 이상 쉬는 게 정상입니다. 그래서 임계값을 늘려야 단어가 안 잘립니다.

침묵 감지는 2초 이상 무음을 "문장 끝"이 아닌 "발화 내 휴지(pause)"로 처리하도록 정책을 잡았고요.

화자 분리는 pyannote.audio를 씁니다. 돌봄 현장에서는 보호자나 TV 소리가 섞이니까, 어르신 목소리만 골라내야 정확도가 올라갑니다.

이 셋 중에서 VAD 재튜닝이 H2 가설의 핵심 변수입니다.

 Slide 12 — Whisper + LoRA (1분 30초)

이제 LoRA를 자세히 설명드리겠습니다.

핵심 수식은 $W = W_0 + B \cdot A$ 입니다. 풀어 말하면 — 원래 모델의 가중치 W_0 는 그대로 두고, B와 A라는 작은 행렬 두 개를 곱한 결과만 더해주는 것입니다.

비유하자면, 두꺼운 사전(W_0)은 건드리지 않고, 포스트잇 두 장(B, A)만 끼워넣어서 사전을 보완하는 거예요. 그래서 "저랭크 분해(Low-Rank Adaptation)"라고 부릅니다.

학습 설정은 표에 정리했는데, 베이스 모델은 Whisper-large-v3, LoRA rank는 8, learning rate는 $1e-4$ 정도로 시작할 계획입니다.

왜 굳이 LoRA를 쓰냐고 물으실 수 있는데, 세 가지 이유입니다. 첫째, GPU 메모리가 Full Fine-Tuning의 10% 수준으로 줄어요. 둘째, 데이터가 적어도 과적합 위험이 낮습니다. 셋째, 원본 모델을 보존하니 어댑터만 갈아끼우면 다른 도메인에도 재활용할 수 있습니다.

 Slide 13 — Ablation 비교군 ★ (1분 30초)

여기가 두 번째로 중요한 페이지입니다. 어떻게 가설을 검증할지 실험 설계를 보여드립니다.

세 가지 실험군을 비교합니다.

E0, Baseline입니다. 그냥 Whisper-large-v3를 zero-shot으로 돌립니다. 파인튜닝도 없고, VAD도 기본값이예요.

E1은 E0에 LoRA 파인튜닝만 추가합니다. E0과 E1의 차이가 곧 H1의 효과 — 즉, PEFT가 정말 효과 있는지를 보여주는 겁니다.

E2는 E1에 노인용 VAD까지 추가합니다. E1과 E2의 차이가 H2의 효과 — VAD 재튜닝이 추가로 도움이 되는지 검증합니다.

이렇게 변수를 단계적으로 하나씩만 추가하는 방식을 Controlled Ablation이라고 합니다. 여러 변수를 한꺼번에 바꾸면 어떤 게 효과를 낸 건지 알 수 없으니까, 한 번에 하나씩만 바꾸는 거죠.

통제 변수는 모두 동일하게 — 같은 테스트셋, 같은 디코딩 설정, 같은 평가 지표를 씁니다.

Slide 14 — 평가지표 & 통계 (1분)

평가는 CER을 주지표로 사용합니다. 한국어는 영어와 달리 단어 경계가 모호하기 때문에, 단어 단위인 WER보다 글자 단위인 CER이 더 적합합니다.

보조지표로는 WER, 처리 속도를 보는 RTF, 그리고 가장 중요한 **오류 유형 분해 (Del/Ins/Sub)**를 봅니다. 이 분해 분석이 H2 검증의 핵심 — VAD 재튜닝으로 Deletion(삭제) 에러가 줄어드는지를 직접 확인합니다.

통계는 paired t-test를 씁니다. 같은 테스트셋을 두 모델에 돌려서 쌍대 비교하니 검정력이 높아지고, bootstrap 95% 신뢰구간으로 안정성도 확인합니다.

성공 기준은 상대 개선율 30% 이상입니다. 절대값 10~12%는 욕심 부리는 stretch goal로만 표기했어요. 이유는 — Whisper baseline 자체의 변동성이 커서 절대값을 약속하기보다 상대 개선율로 평가하는 게 더 일반화 가능한 기준이기 때문입니다.

🗣️ Slide 15 — 기대 결과 + 기각 해석 (1분 30초)

기대 결과는 왼쪽 그래프처럼 $E0 > E1 > E2$ 순으로 CER이 떨어질 거라 예상합니다. ★ 표시한 대로 가상 데이터 기반 예상치고요, 실제 검증이 필요합니다.

그런데 연구에서 더 중요한 건 사실 오른쪽입니다. "가설이 기각되면 어떻게 해석할 것인가" 를 미리 적어놨습니다.

H1이 기각되면 — VOTE400 다양성 부족이거나, LoRA 하이퍼파라미터가 부적합했을 수 있어요. 그러면 Full Fine-Tuning과 직접 비교하는 후속 실험을 설계합니다.

H2가 기각되면 — VAD 외에 디코더의 endpointing이 이미 강건했을 가능성을 보고, beam search나 length penalty 쪽을 추가 ablation 합니다.

이렇게 기각 시 해석 시나리오를 사전에 명시하는 이유는 사후 편향(hindsight bias)을 막기 위해서입니다. 결과를 보고 나서 "원래 그럴 줄 알았다"고 둘러대는 게 아니라, 결과 나오기 전에 미리 약속해두는 거예요. 학술적 엄밀성의 표지입니다. Null result도 과학이다 — 이게 핵심 메시지입니다.

🗣️ Slide 16 — 한계 및 향후 연구 (1분)

본 연구의 한계는 솔직하게 말씀드리면 세 가지입니다.

첫째, VOTE400이 표준어 위주라 사투리 일반화에 한계가 있습니다. 둘째, 일본어 노인 음성 데이터가 없어서 다국어 검증은 본 연구 범위 외입니다. 셋째, 단일 GPU 환경에 8주 일정이라 하이퍼파라미터 탐색 범위가 제한됩니다.

향후 연구로는, 한일 멀티링구얼 확장과, ★ 본 연구자가 작년에 발표한 FI-SMOTE v4 기법을 음성 임베딩 도메인으로 확장 가능성을 탐색할 계획입니다. 화자군 불균형 완화에 적용해보려는 건데, 본 연구의 검증 범위에서는 명료성을 위해 의도적으로 제외했습니다. 마지막으로 노인 돌봄 앱 통합으로 End-to-End UX 평가까지 이어갈 수 있습니다.

Slide 17 — 결론 (45초)

정리하겠습니다.

첫째, 본 연구는 노인 음성 STT의 도메인 갭을 LoRA PEFT로 해결하는 가설 H1·H2를 통계적으로 검증합니다. 둘째, VOTE400 + Whisper-large-v3 + LoRA의 결합은 한국어 노인 음성 STT의 새로운 baseline이 될 수 있습니다. 셋째, 검증 결과는 노인 돌봄 AI 서비스의 핵심 기술 자산으로 활용될 것입니다.

참고문헌은 우측에 정리했고, 마지막 [7]번이 본 연구자의 선행 연구입니다.

이상으로 발표를 마치겠습니다. 질문 환영합니다. 감사합니다.

발표 팁 5가지

슬라이드 7과 13에서 잠시 멈추세요. 가설과 실험 설계는 발표의 핵심이라 청중이 따라올 시간을 줘야 합니다.

"받아쓰기 시험에서 100자 중 25자 틀리는 셈" 같은 비유를 적극 활용하세요. 청중이 숫자를 체감합니다.

"왜 LoRA?", "왜 상대 개선율?" 같은 질문을 발표자가 먼저 던지고 답하세요. 질의응답이 줄어듭니다.

Null result 부분(슬라이드 15)을 강조하세요. "결과 나오기 전에 해석을 미리 약속한다"는 부분이 교수님이 좋아할 포인트입니다.

마지막에 본인 선행연구(FI-SMOTE) 한 번만 언급하면 충분함